

Amazon Fashion 멀티모달 평점 예측 시스템

9-Model Architectural Journey

RoBERTa x MobileNet 기반 Cross-Modal Attention 아키텍처 진화 연구

0.3532

최종 MAE

83.7%

R2 Score

9개

총 모델 수

NVIDIA Blackwe

학습 환경

리뷰 텍스트 · 상품 이미지 · 가격 · 카테고리 4가지 모달리티를 융합하여
패션 상품 평점(1~5점)을 예측하는 딥러닝 시스템을 단계적으로 고도화한
멀티모달 아키텍처 진화 연구 보고서입니다.

TASK 1 · 학술 및 기술 발표 자료

슬라이드 1 -- 프로젝트 개요

발표 핵심 메시지: 4가지 모달리티(텍스트·이미지·가격·카테고리) 융합으로 패션 상품 평점 예측 -> 최종 MAE 0.3532 / R2 83.7% 달성

본 프로젝트는 Amazon 패션 리뷰 데이터셋을 활용하여 RoBERTa(텍스트)와 MobileNet-V3-Large(이미지)를 핵심 백본으로 사용하는 멀티모달 딥러닝 시스템을 9단계에 걸쳐 고도화한 연구입니다. 단순 피쳐 연결(Concatenation)에서 시작하여 Multi-Layer Cross-Modal Attention + Hard Negative Contrastive Learning까지 도달하는 아키텍처 진화 여정을 담고 있습니다.

슬라이드 2 -- 9-Model 실험 로드맵 (Architecture Evolution Timeline)

단계	이미지 백본	Fusion 모듈	핵심 변경사항
Model 1	MobileNet-V2 (HF)	Three-Way GMU	베이스라인 / Targeted Dropout(text=0.8) / 2-Phase LR
Model 2	MobileNet-V2 (TV)	GMU	이미지 파이프라인 Torchvision 통일
Model 3	MobileNet-V3-Large	GMU	V3-Large 업그레이드 + TrivialAugmentWide
Model 4	MobileNet-V3-Large	CrossAttentionFusion	GMU->Cross-Attn 전환 / Dropout완화(0.4) / 가격 노이즈
Model 5	MobileNet-V2 (patch)	Custom QKV Attention	CCR+Soft CCS Loss 최초 도입 / 패치 레벨 피쳐
Model 6	MobileNet-V3-Large	Intra->Inter Attn	Intra-Modality Self-Attention 계층 추가
Model 7	MobileNet-V3-Large	Intra->Inter + CCR/CCS	V6 구조 + Soft CCS 재통합
Model 8	MobileNet-V3-Large	Multi-Layer(2층) + Hard	Cross-Attn 2층 스택 / Hard Negative CCS / 5 Epoch
Model 9 v1	MobileNet-V3-Large	Multi-Layer + Hard	V8 동일 아키텍처 / Epochs 10 (2+8) / 최적 스케줄
Model 9 v2	MobileNet-V3-Large	Multi-Layer + Hard	Fashion CLIP 사전학습 가중치 이식 + AMP + Grad Clip

슬라이드 3 -- 아키텍처 진화의 3대 전환점

전환점 ① Fusion 패러다임 교체 (Model 3 -> Model 4)

- 문제: GMU는 각 모달리티를 독립 인코딩 후 가중합 -> 교차 정보 반영 불가
- 해결: Cross-Attention -- Text가 Image를 참조(Q=Text, KV=Image) + 역방향 동시 수행
- 효과: 텍스트 리뷰 내용과 관련 있는 이미지 영역이 동적으로 강조됨

전환점 ② 대조 손실 도입 (Model 4 -> Model 5)

- 문제: Weighted MSE만으로는 Attention이 의미 있는 영역에 집중하는지 보장 불가
- CCR Loss: 어텐션 점수 상위 K 패치 ↔ 텍스트 임베딩 가깝게 / 하위 K 패치 멀게 (Triplet)
- CCS Loss: 진짜 쌍(text_i, image_i) > 잘못된 쌍(text_j, image_i) 정렬 강제
- V8~V9 개선: Soft(랜덤 Roll) CCS -> Hard Negative CCS (배치 내 최고 유사도 오답 선별)

전환점 ③ Intra-Self-Attention + Multi-Layer 스택 (Model 6 -> Model 8)

- 문제: 단일 Cross-Attention층은 모달리티 내부 관계(토큰 간, 패치 간)를 무시
- 개선1: IntraModalitySelfAttention -- 각 모달리티 시퀀스 자체 정제 (heads=4)
- 개선2: CrossAttentionBlock x 2층 스택 -- 정제된 표현이 상호 2회 교차 융합

- 효과: 계층적 멀티모달 융합으로 표현력 극대화 (V8-V9의 핵심 아키텍처)

슬라이드 4 -- 이전 모델 한계점 vs. Model 9 해결책

문제 영역	Model 1~7 한계	Model 9 해결책
Fusion 깊이	Cross-Attn 단일층, 1회 교차에 그침	2층 Cross-Attn 스택 -- 층별 반복 정교화
Negative 품질	CCS에 랜덤 Roll -- 쉬운 Negative만 사용	Hard Negative CCS -- 유사도 행렬로 어려운 오답 선별
학습 수렴	5 Epoch로 Phase 2 잠재력 미실현	10 Epoch (2 Frozen + 8 Unfrozen) -- 완전 수렴
이미지 피처	AdaptiveAvgPool -> 단일 벡터, 공간 정보 소실	$7 \times 7 = 49$ 패치 시퀀스 보존 -> Sequence-level Cross-Attn
인프라 (v2)	GPU 메모리 비효율, 중단 시 재학습 필요	AMP(FP16) + Gradient Clipping + Checkpoint Resume

슬라이드 5 -- 최종 모델 성과 요약

평가 지표	V9 v1 (표준 학습)	V9 v2 (CLIP 사전학습)	우수 모델
MAE (낮을수록 우수)	0.3532 ★	0.3630	v1 (+2.7%)
MSE	0.3345 ★	0.3656	v1 (+8.5%)
R2 Score (설명력)	0.8368 ★	0.8217	v1 (+1.5%p)
학습 환경	Local GPU	NVIDIA Blackwell (RunPod)	--
특화 강점	Low Bias (수렴성)	Low Variance (일반화)	--

결론 3줄 요약

- 최우수 단독 모델: V9 v1 -- MAE 0.3532 / R2 83.7% (표준 2-Phase 커리큘럼 학습 압승)
- v2 성능 역전 원인: Fashion CLIP 사전학습 공간 ↔ Hard Negative CCS 목적함수 충돌 (Representation Shift + Catastrophic Forgetting)
- 권장 프로덕션 전략: v1(60%) + v2(40%) Soft Voting Ensemble -> 이론상 MAE 0.33대 추가 하락 (NeurIPS 2017 Deep Ensembles 근거)

발표 핵심 메시지: 9번의 아키텍처 진화 끝에 Multi-Layer Cross-Attention + Hard Negative CCS로

패션 평점 변동성의 83.7%를 설명하는 MAE 0.3532 예측 정밀도 달성

TASK 2 · Model 9 아키텍처 정밀 분석

2-1. RoBERTa 텍스트 인코더 상세 분석

Max Token Length: 128

모델	roberta-base (HuggingFace, 125M 파라미터)
max_length	128 (RoBERTa 최대 512의 1/4)
padding	max_length -- 모든 샘플 128 토큰 고정 패딩
truncation	True -- 128 초과 텍스트 잘라냄
return_tensors	pt -- PyTorch Tensor 반환

128 선택의 엔지니어링적 의미: Self-Attention 복잡도 $O(n^2)$ 기준으로 512 대비 메모리 16배 절감. 패션 리뷰의 평균 문장 길이가 짧아 128 토큰으로 의미 커버리지 충분. Batch 4 x Accumulation 4 = Effective Batch 16 환경에서 VRAM 균형 확보.

코드 근거 -- Tokenizer 호출부 (v9.py L61)

```
enc = tokenizer(text, padding="max_length", truncation=True,
                max_length=128, return_tensors="pt")
```

결정적 아키텍처 변화: pooler_output -> last_hidden_state

```
# v1~v4 (pooler_output -- [CLS] 단일 벡터 [B, 768])
t_feat = self.text_fc(self.text_encoder(ids, mask).pooler_output)

# v9 (last_hidden_state -- 전체 시퀀스 [B, 128, 768])
t_outputs = self.text_encoder(ids, attention_mask=mask)
t_seq = self.text_proj(t_outputs.last_hidden_state) # [B,128,256]
```

last_hidden_state 사용으로 128개 토큰 전체 문맥 표현이 이미지 49개 패치와 직접 교차할 수 있게 됨. 이것이 V5 이후 Cross-Attention이 실질적 의미를 갖게 된 핵심 이유.

학습률 스케줄 (2-Phase Curriculum Learning)

Phase 1 (Epoch 1-2)	text_encoder 완전 동결 (requires_grad=False)
Phase 1 -- image LR	2e-5 기타 모듈(proj/fusion/regressor): 1e-4
Phase 2 (Epoch 3-10)	text_encoder Unfreeze -> LR 5e-6 (극미세 Fine-tuning)
Phase 2 -- image LR	1e-5 기타 모듈: 1e-4
스케줄러	CosineAnnealingLR (각 Phase 독립 T_max)

2-2. MobileNet V3-Large 이미지 인코더 상세 분석

입력 이미지 처리 파이프라인

```
v3_weights = models.MobileNet_V3_Large_Weights.DEFAULT
base_transform = v3_weights.transforms() # 공식 ImageNet 전처리 자동 로드
train_transform = transforms.Compose([
    transforms.TrivialAugmentWide(), # 강력 자동 증강
    transforms.RandomHorizontalFlip(), # 패션 이미지 좌우 대칭
    base_transform # 공식 전처리
])
```

공식 전처리 스펙 (MobileNet_V3_Large_Weights.DEFAULT)

처리 단계	값	비고
Resize	232x232	짧은 변 기준 Bilinear
CenterCrop	224x224	최종 입력 해상도
Normalize mean	[0.485, 0.456, 0.406]	ImageNet RGB 평균
Normalize std	[0.229, 0.224, 0.225]	ImageNet RGB 표준편차
Padding	코드 내 미지정 (기본값 사용 추정)	기본 CenterCrop 방식 내 포함

이미지 특성 추출 및 패치 시퀀스 변환

```
# 모델 구성 (v9.py L230-232)
mobilenet = models.mobilenet_v3_large(weights=...DEFAULT)
self.image_encoder = mobilenet.features # Classifier head 제거
self.image_proj = nn.Linear(960, hidden_dim) # 960 -> 256

# Forward (v9.py L252-255)
img_feat = self.image_encoder(pixels) # [B, 960, 7, 7]
B, C, H, W = img_feat.shape # C=960, H=W=7
i_seq = img_feat.view(B, C, H*W).transpose(1,2) # [B, 49, 960]
i_seq = self.image_proj(i_seq) # [B, 49, 256]
```

항목	값	설명
입력 크기	[B, 3, 224, 224]	RGB 이미지
features 출력	[B, 960, 7, 7]	MobileNet-V3-Large 최종 피쳐맵
유효 총 Stride	32 (=224/7)	Depthwise Separable Conv 누적
공간 패치 수	49 (=7x7)	이미지를 49개 '시각 토큰'으로 분할
풀링 레이어	없음 (제거)	v1~v4의 AdaptiveAvgPool2d 제거
Projection	Linear(960->256)	공통 hidden_dim=256 공간으로 정렬

v1~v4 vs v9 이미지 피쳐 처리 비교

- [v1~v4] AdaptiveAvgPool2d -> [B, 960, 1, 1] -> flatten -> [B, 960] -- 공간 정보 완전 소실
- [v9] feat.view -> transpose -> [B, 49, 960] -> Linear -> [B, 49, 256] -- 49 패치 시퀀스 보존

MobileNet features [B,49,960] —> Linear(960,256) —> [B,49,256]]
RoBERTa last_hidden [B,128,768] —> Linear(768,256) —> [B,128,256] } 공통 256-d
Tabular (price+cat) [B,34] —> Linear(34,256) —> [B,256]]

모든 모달리티가 hidden_dim=256 공간으로 투영됨으로써 Cross-Attention의 Q·K·V 연산이 차원 불일치 없이 수행되며, 3-Way Gating Network도 동일 256차원 입력으로 학습 가능해집니다.

2-3. V9 v1 vs v2 -- 결정적 차이점 분석

두 버전은 MultitaskFashionModelV9 클래스, InterModalityCrossAttentionV9, IntraModalitySelfAttention 등 모든 레이어 구조가 완전히 동일합니다. 차이는 오직 학습 초기화 방식(가중치 초기값)에 있습니다.

가중치 초기화 전략 비교

항목	V9 v1 (표준 학습)	V9 v2 (CLIP 사전학습)
RoBERTa 초기 가중치	HuggingFace roberta-base (일반 도메인 MLM)	pretrained_fashion_roberta.pth (Fashion CLIP)
MobileNet 초기 가중치	ImageNet 분류 사전학습 기본값	pretrained_fashion_mobilenet.pth (Fashion CLIP)
Phase 1 Text 동결	동일 (2 Epoch Frozen)	동일 (2 Epoch Frozen)
Phase 2 Text LR	동일 (5e-6)	동일 (5e-6)
Phase 2 Image LR	동일 (1e-5)	동일 (1e-5)
기타 모듈 LR	동일 (1e-4)	동일 (1e-4)
AMP (FP16)	미적용	적용 (autocast + GradScaler)
Gradient Clipping	미적용	max_norm=1.0 적용
Checkpoint Resume	미지원	지원 (--resume 플래그)
학습 환경	Local GPU	NVIDIA Blackwell (RunPod, 32GB GDDR7)

V9 v2 전용 코드 (가중치 로드 부분)

```
# v9_runpod.py L540-556
if Path(args.text_pretrained).exists():
    model.text_encoder.load_state_dict(
        torch.load(args.text_pretrained, map_location=device))
if Path(args.image_pretrained).exists():
    model.image_encoder.load_state_dict(
        torch.load(args.image_pretrained, map_location=device))
```

V9 v1 > v2 성능 역전 원인 (학술적 분석)

- 원인 1 -- 표현 공간 전이 불일치(Representation Shift): Fashion CLIP으로 수렴된 표현 공간이 Hard Negative CCS 목적함수와 충돌 -> 표현 공간 왜곡
- 원인 2 -- 재앙적 망각(Catastrophic Forgetting): 사전학습 정보가 강한 회귀 그레이디언트로 덮어쓰워짐 -> CLIP 정렬 정보 일부 소실
- v1의 강점: Phase 1 동결 + Phase 2 극미세 LR(5e-6)으로 처음부터 Cross-Attention과 동기화 공동 수렴 -> 글로벌 미니마 최적 도달

2-4. Model 9 전체 아키텍처 흐름 요약

입력: 텍스트 리뷰 + 상품 이미지 + 가격 + 카테고리

- ① RoBERTa-base -> last_hidden_state [B,128,768]
 - > Linear(768->256) -> [B,128,256]
 - > IntraModalitySelfAttention(heads=4) -> t_seq_self
- ② MobileNet-V3-Large.features -> [B,960,7,7]

-> reshape+transpose -> [B,49,960]
 -> Linear(960->256) -> [B,49,256]
 -> IntraModalitySelfAttention(heads=4) -> i_seq_self

③ price + price_missing + Cat_Embedding(32d)
 -> Linear(34->256)+ReLU -> tab_feat [B,256]

④ InterModalityCrossAttentionV9 (2층 스택)
 Layer1: Text->Image CrossAttn + Image->Text CrossAttn + FFN(4x) + LN
 Layer2: (동일 구조 반복)
 -> t_pooled, i_pooled, final_attn_weights

⑤ 3-Way Gating: Linear(768->256)->ReLU->Linear(256->3)->Softmax
 weighted_sum = w_t*t + w_i*i + w_tab*tab
 fused = fc_fused(cat[weighted_sum, t, i, tab]) [B,256]
 -> Dropout(0.2)

⑥ 예측: Sigmoid(Linear(256->1))*4+1 -> 1.0~5.0 범위
 (fused/text/image 3개 보조 태스크 동시 학습)

Loss = WtMSE_fused + 0.4*WtMSE_text + 0.4*WtMSE_image
 + 0.1*CCR_Triplet + 0.1*CCS_HardNeg_Triplet

하이퍼파라미터 총정리

파라미터	값	적용 위치
Batch Size	4	DataLoader
Accumulation Steps	4	Effective Batch = 16
Total Epochs	10	Phase1: 2 + Phase2: 8
hidden_dim	256	모든 모달리티 공통 투영 차원
Max Token Length	128	RoBERTa Tokenizer
Cross-Attn Layers	2	InterModalityCrossAttentionV9
Attn Heads	4	Intra/Inter 모든 MHA 모듈
FFN Expansion	4x (256->1024->256)	CrossAttentionBlock 내부
Dropout	0.2	fc_fused 레이어
Triplet Margin	0.2	CCR/CCS Triplet Loss
CCR/CCS 가중치	0.1	총 Loss 내 보조 손실 계수
Text LR (Phase1)	Frozen	requires_grad=False
Text LR (Phase2)	5e-6	AdamW
Image LR (Phase1)	2e-5	AdamW
Image LR (Phase2)	1e-5	AdamW
기타 모듈 LR	1e-4	AdamW
스케줄러	CosineAnnealingLR	Phase별 독립 T_max
Cat Embedding Dim	32	카테고리 임베딩

파라미터	Amazon Fashion Multimodal Rating	Prediction -- Page 10 적용 위치
Grad Clip (v2만)	max_norm=1.0	v9_runpod.py 전용
AMP (v2만)	FP16	v9_runpod.py 전용

부록 -- 앙상블 전략 및 학술 방어 요약

___ 권장 앙상블 전략: Weighted Soft Voting (6:4)

$$\text{Ensemble Prediction} = (P_{v1} \times 0.6) + (P_{v2} \times 0.4)$$

v1(수렴성 특화, Low Bias)과 v2(일반화 특화, Low Variance)의 보완적 결합. NeurIPS 2017 Deep Ensembles 이론에 따라 학습 출발점이 다른 두 모델의 앙상블은 단독 모델보다 예측 불확실성(Uncertainty)을 수학적으로 감소시킵니다. 예상 효과: 단독 v1 MAE 0.3532에서 앙상블 후 0.33대 추가 하락.

___ 심사위원 Q&A 방어 핵심 논거

Q1 왜 v2(사전학습)가 v1보다 성능이 낮습니까?

-> Representation Shift + Catastrophic Forgetting -- CLIP 정렬 공간과 Hard Negative CCS 목적함수의 충돌. v1은 처음부터 2단계 커리큘럼으로 동기화 학습하여 이 문제 원천 차단.

Q2 왜 앙상블 비율을 0.6:0.4로 했습니까?

-> 검증 MAE 성능 격차(v1: 0.3532 vs v2: 0.3630) 기반 실험적 조율. 0.5:0.5는 상대적으로 부정확한 v2가 v1 정밀도를 과도하게 희석(Dampening)하는 부작용 발생.

Q3 CCR/CCS Loss가 실제로 효과가 있습니까?

-> V9 학습 곡선에서 Phase 2 Epoch 7~10 동안 과적합 없이 MAE 0.36~0.37 수준을 안정 유지 -- CCR/CCS 보조 손실의 규제 효과 정량적 입증.

